


Model Selection

Asst. Prof. Dr. Waranyu Wongseeree


Department of Electrical and Computer Engineering, KMUTNB

Data




Data	Purpose	Example
Training	Optimize Model	$w_0, w_1, \dots$
Testing Data	Performance Estimation	Reference Error



Cross-validation



เป้าของการเรียนรู้




$$E_{out} \approx 0$$

$$E_{out} \approx E_{in}$$

ความซับซ้อนของแบบจำลอง $\uparrow$ E_{in} $\downarrow$

ความซับซ้อนของแบบจำลอง $\uparrow$ $E_{out} - E_{in} \uparrow$

Noiseless Target




ฟังก์ชันเป้าหมายไม่มีสัญญาณรบกวน $y = \sin(\pi x)$

$$\mathbb{E}_D[E_{out}(g^{(D)})] = \text{bias}^2 + \text{var}$$

- ความซับซ้อนของแบบจำลอง $\uparrow \text{bias}^2 \downarrow E_{out} \downarrow$
- $n \uparrow \text{var} \downarrow E_{out} \downarrow$

Noisy Target





ฟังก์ชันเป้าหมายมีสัญญาณรบกวน $y = \sin(\pi x) + \epsilon$

$$\mathbb{E}_D[E_{out}(g^{(D)})] = \sigma^2 + \text{bias}^2 + \text{var}$$

- ความซับซ้อนของแบบจำลอง $\uparrow \text{bias}^2 \downarrow E_{out} \downarrow$
- $n \uparrow \text{var} \downarrow E_{out} \downarrow$
- σ^2 ลดไม่ได้

ความเอนเอียง ความแปรปรวนและสัญญาณรบกวน



ฟังก์ชันเป้าหมายมีสัญญาณรบกวน $y = \sin(\pi x) + \epsilon$

$$\mathbb{E}_D[E_{out}(g^{(D)})] = \sigma^2 + \text{bias}^2 + \text{var}$$

- ความซับซ้อนของแบบจำลอง $\uparrow \text{bias}^2 \downarrow E_{out} \downarrow$
- $n \uparrow \text{var} \downarrow E_{out} \downarrow$
- σ^2 ลดไม่ได้

การฟิตเกิน (Overfitting)

$$0 @ 0 = 0$$

$$2 @ 2 = 4$$

$$2 @ 3 = 6$$

ตัวดำเนินการ คือ @ อะไร

การฟิตเกิน (Overfitting)

$$0 @ 0 = 0$$

$$2 @ 2 = 4$$

$2 @ 3 = 6$ คำนวณผิดพลาด หรือ สัญญารบกวณในข้อมูลเรียนรู้

$$1 @ 2 = 3$$

$$3 @ 3 = 6$$

ตัวดำเนินการ คือ @ อะไร

การฟิตเกิน (Overfitting)

เป็นปรากฏการณ์ที่ E_{in} น้อย แต่ E_{out} มาก


เกิดขึ้นเมื่อแบบจำลองมีความซับซ้อนมากเกินไปกว่าที่จะเป็นตัวแทนของฟังก์ชันเป้าหมาย

การเพิ่มองศาอิสระเพื่อสร้างแบบจำลองที่เข้ากับข้อมูลที่มีสัญญาณรบกวนส่งผลให้ได้แบบจำลองที่มีประสิทธิภาพต่ำ


นอกจากนี้การฟิตเกินสามารถเกิดขึ้นได้กับแบบจำลองที่ซับซ้อนน้อยกว่าฟังก์ชันเป้าหมาย

Polynomial Regression


Constant function
Degree 0




Linear function
Degree 1




Quadratic function
Degree 2




Cubic function
Degree 3



Quartic function
Degree 4



Quintic function
Degree 5



การทดลอง Model Selection

วัตถุประสงค์

เพื่อให้ทราบวิธีการตรวจจับการเกิด Overfitting

เพื่อให้ทราบสาเหตุของการเกิด Overfitting

เพื่อให้ทราบแนวทางในเลือกแบบจำลองที่เหมาะสม

เพื่อให้ทราบแนวทางการหา sample size

วิธีการทดลอง

1. ใช้ข้อมูล sin ที่มีจำนวนข้อมูลและปริมาณ noise ที่แตกต่างกัน
2. สร้างแบบจำลอง Polynomial Regression ที่มี degree แตกต่างกัน โดยเลือก Test options เป็น Use training set และ Cross-validation
3. บันทึกค่า RMSE, Coefficient ลงในตาราง

รายละเอียดของการทดลอง

	รายละเอียด
ข้อมูล	sin
ตัวแปรต้น	x
ตัวแปรตาม	y
จำนวนข้อมูล	10, 20, 40, 80
Degree of polynomial	1, 3, 8
Noise standard deviation	Noiseless: $sd = 0$, Noisy: $sd = 0.3$
วิธีประเมินประสิทธิภาพ	Resubstitution, CV
Metric	RMSE

ผลการทดลอง

Noiseless	Degree = 1		Degree = 3		Degree = 8	
Sample Size	Training	CV	Training	CV	Training	CV
10						
20						
40						
80						

Noisy	Degree = 1		Degree = 3		Degree = 8	
Sample Size	Training	CV	Training	CV	Training	CV
10						
20						
40						
80						

ผลการทดลอง degree of polynomial = 8

อันดับ	Noiseless N = 10	Noisy N = 10	Noiseless N = 80	Noisy N = 80
w_1				
w_2				
w_3				
w_4				
w_5				
w_6				
w_7				
w_8				
w_0				

ผลการทดลอง degree of polynomial = 3

อันดับ	Noiseless N = 10	Noisy N = 10	Noiseless N = 80	Noisy N = 80
w_0				
w_1				
w_2				
w_3				

การทดลอง Model Selection





คำถาม จะสามารถการตรวจจับการเกิด Overfitting ได้จากการพิจารณาค่าอะไร

คำถาม สาเหตุของการเกิด Overfitting ได้แก่อะไรบ้าง


คำถาม แนวทางในเลือกแบบจำลองที่เหมาะสมพิจารณาจากค่าอะไร

คำถาม แนวทางการหา sample size พิจารณาจากค่าอะไร

การฟิตเกิน






ค่าคลาดเคลื่อน



สัมประสิทธิ์ของแบบจำลอง

อันดับ	0	1	3	9
w_0	0.19	0.82	0.31	0.35
w_1		-1.27	7.99	232.37
w_2			-25.43	-5,321.83
w_3			17.37	48,568.31
w_4				-231,639.30
w_5				640,042.26
w_6				-1,061,800.52
w_7				1,042,400.18
w_8				-557,682.99
w_9				125,201.43



การเพิ่มจำนวนข้อมูล



สาเหตุของการฟิตเกิน

คือ การเลือกแบบจำลองที่มี E_{in} น้อยแต่มี E_{out} สูง

หมายความว่า การพิจารณา E_{in} เพียงอย่างเดียวไม่เพียงพอ สำหรับการสร้างแบบจำลอง




สาเหตุของการฟิตเกิน

แบบจำลองที่มีค่าคลาดเคลื่อนในตัวอย่าง E_{in} เป็นศูนย์ แต่มีค่าคลาดเคลื่อนนอกตัวอย่าง E_{out} มาก จะเป็นแบบจำลองที่มีการวางนัยทั่วไปไม่ดี (Bad Generalization) ซึ่งเป็นผลลัพธ์จากการฟิตเกิน

อย่างไรก็ตามนิยามของการฟิตเกินยังมีมากกว่าเรื่องการวางนัยทั่วไป โดยยังรวมไปถึงกระบวนการเลือกแบบจำลองที่มีค่าคลาดเคลื่อนในตัวอย่าง E_{in} น้อยส่งผลให้มีค่าคลาดเคลื่อนนอกตัวอย่าง E_{out} มาก

กรณีศึกษาที่ 1 Noisy Target



ฟังก์ชันเป้าหมาย คือ พหุนาม
อันดับที่ 10


ข้อมูล 15 ตัวอย่างและมี
สัญญาณรบกวน

$$y = f(x) + \epsilon$$

เมื่อ

$$\epsilon \sim \mathcal{N}(\mu = 0, \sigma^2)$$


กรณีศึกษาที่ 1 Noisy Target



Noisy low-order target

	2nd Order	10th Order
E_{in}	0.050	0.034
E_{out}	0.127	9.00

กรณีศึกษาที่ 2 Noiseless Target




ฟังก์ชันเป้าหมาย คือ พหุนาม
อันดับที่ 50

ข้อมูล 15 ตัวอย่างและไม่มี
สัญญาณรบกวน

$$y = f(x)$$

กรณีศึกษาที่ 2 Noiseless Target



Noiseless high-order target

	2nd Order	10th Order
E_{in}	0.029	10^{-5}
E_{out}	0.120	7680

กรณีศึกษาที่ 1 และ 2

สิ่งที่ขั้นตอนวิธีการเรียนรู้เห็น คือ ข้อมูล ไม่ใช่ฟังก์ชันเป้าหมาย ในทั้งสองปัญหา **พหุนามอันดับที่ 10 เกิดการฟิตเกิน** และส่งผลให้แบบจำลองไม่สมเหตุสมผล เนื่องจากมีความแตกต่างจากฟังก์ชันเป้าหมาย

ขณะที่พหุนามอันดับที่ 2 ที่มีความซับซ้อนไม่เพียงพอที่จะสร้างคุณลักษณะของฟังก์ชันเป้าหมายของทั้งสองปัญหาได้ แต่อย่างน้อยก็สามารถสร้างแนวโน้มโดยทั่วไปของฟังก์ชันเป้าหมายได้ ส่งผลให้มีค่าคลาดเคลื่อนนอกตัวอย่างน้อยกว่า

พหุนามอันดับสูงมีค่าคลาดเคลื่อนในตัวอย่างน้อยกว่าและมีค่าคลาดเคลื่อนนอกตัวอย่างที่สูงกว่านี้จึงเป็นกรณีศึกษาของการฟิตเกินที่นำไปสู่การวางนัยทั่วไปที่ไม่ดี


กรณีศึกษาที่ 3 รู้ฟังก์ชันเป้าหมาย

เพื่อแสดงให้เห็นถึงปรากฏการณ์ที่น่าสนใจบางอย่าง สมมติว่าทราบว่าฟังก์ชันเป้าหมายเป็นพหุนามอันดับที่ 10 และมีข้อมูลทั้งหมด 15 ตัวอย่างที่มีสัญญาณรบกวน

สร้างแบบจำลอง แบบจำลองพหุนามอันดับที่ 10 (H_{10}) และแบบจำลองพหุนามอันดับที่ 2 (H_2)

แบบจำลองไหนเป็นแบบจำลองที่ดีกว่ากัน ?

กรณีศึกษาที่ 3 รู้ฟังก์ชันเป้าหมาย




กรณีศึกษาที่ 3 รู้ฟังก์ชันเป้าหมาย

สิ่งที่น่าแปลกใจ คือ แบบจำลอง H_2 เป็นแบบจำลองที่ดีกว่า (มีค่าคลาดเคลื่อนนอกตัวอย่างน้อยกว่า) โดยใช้แบบจำลองที่ซับซ้อนน้อยกว่า ถึงแม้จะทราบรูปแบบของฟังก์ชันเป้าหมาย **การยอมให้มีค่าคลาดเคลื่อนในตัวอย่างสูง จะทำให้มีค่าคลาดเคลื่อนนอกตัวอย่างต่ำ**

สิ่งที่น่าแปลกใจ คือ ผลลัพธ์ที่ดีที่สุด ควรจะได้มาจากการผสมผสานข้อมูลเกี่ยวกับฟังก์ชันเป้าหมายให้มากที่สุด แต่จากตัวอย่าง ถึงแม้จะทราบอันดับของพหุนามของฟังก์ชันเป้าหมาย แต่การใช้ความรู้นี้แบบง่ายๆ โดยการเลือกแบบจำลองเป็นพหุนามอันดับที่ 10 พบว่าประสิทธิภาพจะแย่กว่าแบบจำลองพหุนามอันดับที่ 2

กรณีศึกษาที่ 4 เส้นโค้งการเรียนรู้

พบว่าแบบจำลองพหุนามอันดับที่ 10 จะมีค่าคลาดเคลื่อนในตัวอย่าง E_{in} น้อย และค่าคลาดเคลื่อนนอกตัวอย่าง E_{out} มาก ที่จำนวนข้อมูลตัวอย่างน้อย ๆ (ในพื้นที่สีเทา)



สาเหตุของการฟิตเกิน

แบบจำลอง H_2 จะมีประสิทธิภาพดีกว่าเสมอหรือไม่ คำตอบคือไม่

ตัวอย่างเช่น หากข้อมูลไม่มีสัญญาณรบกวน แบบจำลอง H_{10} จะสร้างแบบจำลองที่ใกล้เคียงฟังก์ชันเป้าหมาย ขณะที่แบบจำลอง H_2 จะไม่มีประสิทธิภาพเพียงพอ

นำไปสู่ตัวอย่างของการฟิตเกินที่ข้อมูลไม่มีสัญญาณรบกวน แต่ฟังก์ชันเป้าหมายมีความซับซ้อนมาก (พหุนามของอันดับที่ 50) แบบจำลอง H_2 จะมีประสิทธิภาพสูงกว่าแบบจำลอง H_{10} เนื่องจากการฟิตเกินที่เกิดจากความซับซ้อนของฟังก์ชันเป้าหมาย

สาเหตุของการฟิตเกิน

ดังนั้นความซับซ้อนของแบบจำลองจะต้องเหมาะสมกับปริมาณและคุณภาพของข้อมูลที่มี ไม่ใช่เหมาะสมกับความซับซ้อนของฟังก์ชันเป้าหมาย

จำนวนข้อมูลมากขึ้น

การฟิตเกินจะลดลง


สัญญาณรบกวนเพิ่มขึ้น

การฟิตเกินจะเพิ่มขึ้น


ฟังก์ชันเป้าหมายซับซ้อนมากขึ้น

การฟิตเกินจะเพิ่มขึ้น

Bias vs. Variance




Bias vs. Variance




Learning Curve


High bias (Underfit)




High Variance (Overfit)



Learning Curve



การวินิจฉัยความเอนเอียงและความแปรปรวน




High bias

- Training error สูง
- Cross-validation error มีค่าใกล้เคียงกับ Training error

High Variance


- Training error ต่ำ
- Cross-validation error สูง

High Bias





คำถาม จะแก้ปัญหานี้ได้อย่างไร

High Variance




คำถาม จะแก้ปัญหานี้ได้อย่างไร

Learning Curve



Learning Curve ของ Simple Model จะลู่เข้าหากันเร็วกว่า Complex Model แต่ Simple Model จะมี Error สูงกว่า
นั่นคือเมื่อมีจำนวนข้อมูลมากเพียงพอประสิทธิภาพของแบบจำลองอย่างง่ายจะต่ำกว่าแบบจำลองที่ซับซ้อน


Learning Curve




เมื่อจำนวนตัวอย่างเพิ่มขึ้น
พบว่าความแปรปรวนของ
แบบจำลองจะลดลง ดังนั้นค่า
Validation Error จะลดลง

Data

Data	Purpose	Example
Training	Optimize Model	$w_0, w_1, \dots$
Validation	Optimize Hyperparameter	Degree of polynomial
Testing Data	Performance Estimation	Reference Error




Nested Cross-Validation



A detailed experiment

Impact of **noise level** and **target complexity**



$$y = f(x) + \underbrace{\epsilon(x)}_{\sigma^2} = \sum_{q=0}^{Q_f} \alpha_q x^q + \epsilon(x)$$

normalized

noise level: σ^2

target complexity: Q_f

data set size: N


The polynomial model

$\mathcal{H}_Q$: polynomials of order Q

linear regression in $\mathcal{Z}$ space

$$\mathbf{z} = \begin{bmatrix} 1 \\ L_1(x) \\ \vdots \\ L_Q(x) \end{bmatrix} \quad \mathcal{H}_Q = \left\{ \sum_{q=0}^Q w_q L_q(x) \right\}$$

Legendre polynomials:



The overfit measure

We fit the data set $(x_1, y_1), \dots, (x_N, y_N)$ using our two models:

$\mathcal{H}_2$: 2nd-order polynomials

$\mathcal{H}_{10}$: 10th-order polynomials




Compare out-of-sample errors of


$g_2 \in \mathcal{H}_2$ and $g_{10} \in \mathcal{H}_{10}$

overfit measure: $E_{\text{out}}(g_{10}) - E_{\text{out}}(g_2)$

The results



Impact of “noise”



number of data points	↑	Overfitting	↓
stochastic noise	↑	Overfitting	↑
deterministic noise	↑	Overfitting	↑