

# Bayes' theorem

Asst. Prof. Dr. Waranyu Wongseeree


Faculty of Digital Technology

Chitralada Technology Institute

# การจำแนก

คือการสร้างแบบจำลองทางคณิตศาสตร์สำหรับการรู้จำแบบรูป (Pattern) ตัวอย่าง (Sample) สัญญาณ (Signal) หรือรูปภาพ (Image) โดยอัตโนมัติจากลักษณะประจำ (Attribute หรือ Feature) จากการวัด หรือการสังเกต

# การแบ่งประเภทรู้จำแบบ



# ทฤษฎีการตัดสินใจแบบเบย์

| PSA (x) | Class (y) |
|---------|-----------|
| 4.1     | Cancer    |
| 3.4     | Cancer    |
| 2.9     | Cancer    |
| 2.8     | Cancer    |
| 2.7     | Cancer    |
| 2.1     | Cancer    |
| 1.6     | Cancer    |

| PSA (x) | Class (y) |
|---------|-----------|
| 2.5     | Healthy   |
| 2.0     | Healthy   |
| 1.7     | Healthy   |
| 1.4     | Healthy   |
| 1.2     | Healthy   |
| 0.9     | Healthy   |
| 0.8     | Healthy   |

ความน่าจะเป็นของเหตุการณ์  $y$  เมื่อให้หลักฐาน  $x$

$$P(y|x) = \frac{P(x|y)P(y)}{P(x)}$$

# ทฤษฎีการตัดสินใจแบบเบส์

| PSA (x) | Class (y) |
|---------|-----------|
| 4.1     | Cancer    |
| 3.4     | Cancer    |
| 2.9     | Cancer    |
| 2.8     | Cancer    |
| 2.7     | Cancer    |
| 2.1     | Cancer    |
| 1.6     | Cancer    |
| 2.5     | Healthy   |
| 2.0     | Healthy   |
| 1.7     | Healthy   |
| 1.4     | Healthy   |
| 1.2     | Healthy   |
| 0.9     | Healthy   |
| 0.8     | Healthy   |

ความน่าจะเป็นของเหตุการณ์  $y$  เมื่อให้หลักฐาน  $x$

$$P(y|x) = \frac{P(x|y)P(y)}{P(x)}$$

$P(y)$  คือ ความน่าจะเป็นก่อน (Prior probability)

$$P(\text{Class} = \text{Cancer}) = 0.5$$

$$P(\text{Class} = \text{Healthy}) = 0.5$$

ความน่าจะเป็นก่อนสามารถประมาณจากสัดส่วนของ  
คลาสจากตัวอย่าง

# ทฤษฎีการตัดสินใจแบบเบย์

| PSA (x) | Class (y) |
|---------|-----------|
| 4.1     | Cancer    |
| 3.4     | Cancer    |
| 2.9     | Cancer    |
| 2.8     | Cancer    |
| 2.7     | Cancer    |
| 2.1     | Cancer    |
| 1.6     | Cancer    |
| 2.5     | Healthy   |
| 2.0     | Healthy   |
| 1.7     | Healthy   |
| 1.4     | Healthy   |
| 1.2     | Healthy   |
| 0.9     | Healthy   |
| 0.8     | Healthy   |


ความน่าจะเป็นของเหตุการณ์  $y$  เมื่อให้หลักฐาน  $x$

$$P(y|x) = \frac{P(x|y)P(y)}{P(x)}$$

$P(x|y)$  คือ ความน่าจะเป็นมีเงื่อนไขคลาส (Class-Conditional Probability)

# ความน่าจะเป็นมีเงื่อนไขคลาส (Class-Conditional Probability)


| PSA (x) | Class (y) | Statistics                        |
|---------|-----------|-----------------------------------|
| 4.1     | Cancer    | $\bar{x}_2 = 2.8$<br>$s_2 = 0.82$ |
| 3.4     | Cancer    |                                   |
| 2.9     | Cancer    |                                   |
| 2.8     | Cancer    |                                   |
| 2.7     | Cancer    |                                   |
| 2.1     | Cancer    |                                   |
| 1.6     | Cancer    |                                   |
| 2.5     | Healthy   | $\bar{x}_1 = 1.5$<br>$s_1 = 0.61$ |
| 2.0     | Healthy   |                                   |
| 1.7     | Healthy   |                                   |
| 1.4     | Healthy   |                                   |
| 1.2     | Healthy   |                                   |
| 0.9     | Healthy   |                                   |
| 0.8     | Healthy   |                                   |



$$P(\text{PSA} = 2.6 | \text{Healthy}) = 0.13$$

# ความน่าจะเป็นมีเงื่อนไขคลาส (Class-Conditional Probability)

| PSA (x) | Class (y) | Statistics                        |
|---------|-----------|-----------------------------------|
| 4.1     | Cancer    | $\bar{x}_2 = 2.8$<br>$s_2 = 0.82$ |
| 3.4     | Cancer    |                                   |
| 2.9     | Cancer    |                                   |
| 2.8     | Cancer    |                                   |
| 2.7     | Cancer    |                                   |
| 2.1     | Cancer    |                                   |
| 1.6     | Cancer    |                                   |
| 2.5     | Healthy   | $\bar{x}_1 = 1.5$<br>$s_1 = 0.61$ |
| 2.0     | Healthy   |                                   |
| 1.7     | Healthy   |                                   |
| 1.4     | Healthy   |                                   |
| 1.2     | Healthy   |                                   |
| 0.9     | Healthy   |                                   |
| 0.8     | Healthy   |                                   |



$$P(\text{PSA} = 2.6 | \text{Cancer}) = 0.47$$



# ความน่าจะเป็นมีเงื่อนไขคลาส (Class-Conditional Probability)

| PSA (x) | Class (y) |
|---------|-----------|
| 4.1     | Cancer    |
| 3.4     | Cancer    |
| 2.9     | Cancer    |
| 2.8     | Cancer    |
| 2.7     | Cancer    |
| 2.1     | Cancer    |
| 1.6     | Cancer    |
| 2.5     | Healthy   |
| 2.0     | Healthy   |
| 1.7     | Healthy   |
| 1.4     | Healthy   |
| 1.2     | Healthy   |
| 0.9     | Healthy   |
| 0.8     | Healthy   |

ความน่าจะเป็น (Likelihood) ที่ PSA = 2.6 เมื่อ  
พิจารณากลุ่ม Cancer

$$P(\text{PSA} = 2.6 | \text{Cancer}) = 0.47$$

ความน่าจะเป็น (Likelihood) ที่ PSA = 2.6 เมื่อ  
พิจารณากลุ่ม Healthy

$$P(\text{PSA} = 2.6 | \text{Healthy}) = 0.13$$

## ความน่าจะเป็นมีเงื่อนไขคลาส (Class-Conditional Probability)

| PSA (x) | Class (y) |
|---------|-----------|
| 4.1     | Cancer    |
| 3.4     | Cancer    |
| 2.9     | Cancer    |
| 2.8     | Cancer    |
| 2.7     | Cancer    |
| 2.1     | Cancer    |
| 1.6     | Cancer    |
| 2.5     | Healthy   |
| 2.0     | Healthy   |
| 1.7     | Healthy   |
| 1.4     | Healthy   |
| 1.2     | Healthy   |
| 0.9     | Healthy   |
| 0.8     | Healthy   |

ความน่าจะเป็น (Likelihood) ที่ PSA = 2.6 เมื่อ  
พิจารณากลุ่ม Cancer

$$P(\text{PSA} = 2.6 | \text{Cancer}) = 0.47$$

ความน่าจะเป็น (Likelihood) ที่ PSA = 2.6 เมื่อ  
พิจารณากลุ่ม Healthy

$$P(\text{PSA} = 2.6 | \text{Healthy}) = 0.13$$

## ความน่าจะเป็นภายหลัง (Posteriori probability)

$$P(y|x) = \frac{P(x|y)P(y)}{P(x)}$$

$$\begin{aligned} & P(\text{Class} = \text{Cancer} | \text{PSA} = 2.6) \\ &= \frac{P(\text{PSA} = 2.6 | \text{Class} = \text{Cancer}) P(\text{Class} = \text{Cancer})}{P(x)} \\ &= \frac{0.5 \cdot 0.47}{0.5 \cdot 0.13 + 0.5 \cdot 0.47} = 0.79 \end{aligned}$$



$$\begin{aligned} & P(\text{Class} = \text{Healthy} | \text{PSA} = 2.6) \\ &= \frac{P(\text{PSA} = 2.6 | \text{Class} = \text{Healthy}) P(\text{Class} = \text{Healthy})}{P(x)} \\ &= \frac{0.5 \cdot 0.13}{0.5 \cdot 0.13 + 0.5 \cdot 0.47} = 0.21 \end{aligned}$$

## ตัวอย่างการจำแนก

การจำแนกพันธุ์ไอริสโดยใช้ข้อมูลเข้าหรือลักษณะประจำเป็นความยาวกลีบเลี้ยง (Sepal Length) ความกว้างกลีบเลี้ยง (Sepal Width) ความยาวกลีบดอก (Petal Length) และความกว้างกลีบดอก (Petal Width)



# ฮิสโทแกรมของความยาวและความกว้างกลีบดอกไอริส




เลือกความยาวหรือความกว้างกลีบดอกค่าหนึ่งเพื่อใช้เป็นขีดเริ่มเปลี่ยน (Threshold) สำหรับการสร้างขอบตัดสินใจ (Decision Boundary)

# ตัวจำแนกเชิงเส้น (Linear Discriminant)

การใช้ลักษณะประจำตัวเดียวไม่  
เพียงพอสำหรับการเลือกซื้อเริ่ม  
เปลี่ยนเพื่อการตัดสินใจ

ปรากฏการณ์ดังกล่าวเรียกว่า  
การเข้ากับตัวอย่างน้อยกว่า  
พอเหมาะ (Underfitting)

ค่าคลาดเคลื่อนการจำแนกมี  
ค่าต่ำกว่าตัวจำแนกเชิงเส้นตัวแปร  
เดียว




# ตัวจำแนกไม่เชิงเส้น (Non-linear Discriminant)

ขอบตัดสินใจมีลักษณะ  
ซับซ้อนเกินไป ส่งผลให้ตัวจำแนก  
ไม่สามารถจำแนกพันธุ์ไอริสที่ไม่  
เคยใช้สร้างตัวจำแนกได้


ปรากฏการณ์ดังกล่าวเรียกว่า  
การเข้ากับตัวอย่างเกินพอเหมาะ  
(Overfitting)

แก้ปัญหาโดยการเพิ่มจำนวน  
ตัวอย่าง แต่ในทางปฏิบัติมักมี  
จำนวนตัวอย่างไม่เพียงพอ



# ตัวจำแนกที่เหมาะสม

การสร้างตัวจำแนกจึงต้องมี  
ความสมดุลระหว่างสมรรถนะการ  
จำแนกและความซับซ้อนของตัว  
จำแนก





# การจำแนกโดยใช้ทฤษฎีการตัดสินใจแบบเบส


- $p(c_1)$  แทนความน่าจะเป็นที่จะพบ *Iris versicolor* และ
- $p(c_2)$  แทนความน่าจะเป็นที่จะพบ *Iris virginica*
- ถ้าไม่มีไอริสพันธุ์อื่น แล้วผลรวมของความน่าจะเป็นจะมีค่าเท่ากับหนึ่ง
- ความน่าจะเป็นนี้เรียกว่าความน่าจะเป็นก่อน (Prior Probability)
- ความน่าจะเป็นก่อนสามารถประมาณจากสัดส่วนของคลาสจากเซตตัวอย่าง (Sample Set)

# การจำแนกโดยใช้ทฤษฎีการตัดสินใจแบบเบย์



$p(x|c_i)$  ความน่าจะเป็นมี  
เงื่อนไขคลาส (Class-  
Conditional Probability)  
อธิบายการแจกแจงตัวอย่างเข้า

$$p(c_i | x) = \frac{p(x | c_i) p(c_i)}{p(x)}$$


$$p(x) = \sum_{i=1}^2 p(x | c_i) p(c_i)$$



# การจำแนกโดยใช้ทฤษฎีการตัดสินใจแบบเบย์



# การจำแนกโดยใช้ทฤษฎีการตัดสินใจแบบเบย์



## กฎตัดสินใจ (Decision Rule)

- ถ้าตัวจำแนกตัดสินใจให้ตัวอย่างเข้ามาจากคลาสที่ความน่าจะเป็นภายหลังสูงสุด
- แล้วจะทำให้ค่าคลาดเคลื่อนมีเงื่อนไขตัวอย่างเข้ามีค่าต่ำสุด
- ดังนั้นกฎตัดสินใจจึงสามารถอธิบายได้โดย

If  $p(c_1 | x) > p(c_2 | x)$  then classify  $x$  as belonging to  $c_1$ , otherwise classify  $x$  as belonging to  $c_2$ .

## ฟังก์ชันจำแนก (Discriminant Function)

- เนื่องจากความน่าจะเป็นภายหลังมักอธิบายโดยใช้ฟังก์ชันเลขชี้กำลัง
- การใช้ประยุกต์ใช้ฟังก์ชันเพิ่มทางเดียวกับความน่าจะเป็นภายหลังจะให้ผลการวิเคราะห์ตรงกัน และจะเรียกว่าฟังก์ชันจำแนก

$$\begin{aligned} g_i(x) &= \ln(p(c_i | x)) \\ &= \ln\left(\frac{p(x | c_i)p(c_i)}{p(x)}\right) \end{aligned}$$

- และกฎตัดสินใจสามารถอธิบายได้โดย

If  $g_1(x) > g_2(x)$  then classify  $x$  as belonging to  $c_1$ , otherwise classify  $x$  as belonging to  $c_2$ .

## ขอบตัดสินใจ (Decision Boundary)

$$g(x) = g_1(x) - g_2(x) = 0$$

หรือ

$$\begin{aligned}\ln(p(c_1 | x)) - \ln(p(c_2 | x)) &= \ln\left(\frac{p(c_1 | x)}{p(c_2 | x)}\right) \\ &= \ln\left(\frac{p(x | c_1)p(c_1)}{p(x)} \times \frac{p(x)}{p(x | c_2)p(c_2)}\right) \\ &= \ln\left(\frac{p(x | c_1)}{p(x | c_2)}\right) + \ln\left(\frac{p(c_1)}{p(c_2)}\right) \\ &= 0\end{aligned}$$

# กฎตัดสินใจและขอบตัดสินใจกรณีหลายคลาส

กรณีปัญหาการจำแนกประกอบด้วยหลายคลาส กฎตัดสินใจสามารถอธิบายได้โดย

|                                                                                  |
|----------------------------------------------------------------------------------|
| If $g_i(x) > g_j(x), \forall j \neq i$ then classify $x$ as belonging to $c_i$ . |
|----------------------------------------------------------------------------------|

และขอบตัดสินใจสามารถอธิบายได้โดย

$$g_{ij}(x) = g_i(x) - g_j(x) = 0, \quad \forall j \neq i \quad (1-10)$$




# ทฤษฎีการตัดสินใจแบบเบส

ตัวจำแนกมีสองส่วนประกอบสำคัญ คือ ความน่าจะเป็นมีเงื่อนไขคลาส และความน่าจะเป็นก่อน

กรณีที่ทราบฟังก์ชันความน่าจะเป็นมีเงื่อนไขคลาส การแก้ปัญหการจำแนกจะเป็นเพียงการประมาณค่าพารามิเตอร์ของการแจกแจง และจะเรียกวิธีการแก้ปัญหานี้ว่าเทคนิคอิงพารามิเตอร์

ถ้าไม่ทราบฟังก์ชันความน่าจะเป็นมีเงื่อนไขคลาส จะต้องประมาณฟังก์ชันความน่าจะเป็นมีเงื่อนไขคลาสหรือสร้างขอบตัดสินใจโดยการประมาณความน่าจะเป็นภายหลัง ทั้งสองวิธีแก้ปัญหานี้เรียกว่าเทคนิคไม่อิงพารามิเตอร์

# ทฤษฎีการตัดสินใจแบบเบส์



More knowledge

Less knowledge

# การแก้ปัญหาการจำแนกโดยใช้เทคนิคอิงพารามิเตอร์

การแจกแจงปกติซึ่งเหมาะสมสำหรับกรณีตัวอย่างเข้าประกอบด้วย  
ลักษณะประจำค่าต่อเนื่อง (Continuous-Valued Attribute)

และการแจกแจงแบร์นูลลี (Bernoulli Distribution) ซึ่งเหมาะสม  
สำหรับกรณีตัวอย่างเข้าประกอบด้วยลักษณะประจำค่าวิยุต (Discrete-  
Valued Attribute)

## การแจกแจงปกติตัวแปรเดียว

$$p(r) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left[-\frac{1}{2}\left(\frac{r-\mu}{\sigma}\right)^2\right]$$

เมื่อ


$$\mu = E[r]$$

$$= \int_{-\infty}^{\infty} rp(r)dr$$

และ

$$\sigma^2 = E[(r-\mu)^2]$$

$$= \int_{-\infty}^{\infty} (r-\mu)^2 p(r)dr$$



# ตัวจำแนกแบบเบส์สำหรับการแจกแจงปรกติตัวแปรเดียว

เมื่อใช้การแจกแจงปรกติเป็นฟังก์ชันความหนาแน่นความน่าจะเป็นมีเงื่อนไขคลาส

$$p(r) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left[-\frac{1}{2}\left(\frac{r-\mu}{\sigma}\right)^2\right]$$

ฟังก์ชันจำแนกจะเป็นฟังก์ชันกำลังสอง (Quadratic Function)

$$g_i(x) = -\frac{(x-\mu_{c_i})^2}{2\sigma_{c_i}^2} - \frac{1}{2}\ln 2\pi - \ln \sigma_{c_i} + \ln p(c_i) - \ln p(x)$$

## Single Threshold



$$g_i(x) = -\frac{(x - \mu_{c_i})^2}{2\sigma_{c_i}^2} - \frac{1}{2} \ln 2\pi - \ln \sigma_{c_i} + \ln p(c_i) - \ln p(x)$$

ถ้าสมมติให้ความน่าจะเป็นก่อนและความแปรปรวนของทั้งสองคลาสมีค่าเท่ากัน แล้วจะได้ขอบตัดสินใจเป็น


$$\begin{aligned} g(x) &= g_1(x) - g_2(x) \\ &= -\frac{(x - \mu_{c_1})^2}{2\sigma_c^2} + \frac{(x - \mu_{c_2})^2}{2\sigma_c^2} \\ &= 0 \end{aligned}$$

นั่นคือ

$$x = \frac{\mu_{c_1} + \mu_{c_2}}{2}$$



# ผลจากค่า Prior Probability







## Double Threshold

$$g_i(x) = -\frac{(x - \mu_{c_i})^2}{2\sigma_{c_i}^2} - \frac{1}{2} \ln 2\pi - \ln \sigma_{c_i} + \ln p(c_i) - \ln p(x)$$

ถ้าสมมติให้ความน่าจะเป็นก่อนของทั้งสองคลาสมีค่าเท่ากัน แต่ความแปรปรวนของทั้งสองคลาสมีค่าไม่เท่ากัน แล้วจะได้ขอบตัดสินใจเป็น

$$\begin{aligned} g(x) &= g_1(x) - g_2(x) \\ &= -\frac{(x - \mu_{c_1})^2}{2\sigma_{c_1}^2} - \ln \sigma_{c_1} + \frac{(x - \mu_{c_2})^2}{2\sigma_{c_2}^2} + \ln \sigma_{c_2} \\ &= 0 \end{aligned}$$

ขอบตัดสินใจจะเปลี่ยนเป็นสองขีดเริ่มเปลี่ยน



## ตัวจำแนกแบบเบส์สำหรับการแจกแจงปรกติหลายตัวแปร

$$p(\mathbf{r}) = \frac{1}{(2\pi)^{D/2} |\mathbf{\Sigma}|^{1/2}} \exp \left[ -\frac{1}{2} (\mathbf{r} - \boldsymbol{\mu})^T \mathbf{\Sigma}^{-1} (\mathbf{r} - \boldsymbol{\mu}) \right]$$

เมื่อ

$$\boldsymbol{\mu} = E[\mathbf{r}] = \int_{-\infty}^{\infty} \mathbf{r} p(\mathbf{r}) d\mathbf{r}$$

และ

$$\mathbf{\Sigma} = E[(\mathbf{r} - \boldsymbol{\mu})(\mathbf{r} - \boldsymbol{\mu})^T] = \int_{-\infty}^{\infty} (\mathbf{r} - \boldsymbol{\mu})(\mathbf{r} - \boldsymbol{\mu})^T p(\mathbf{r}) d\mathbf{r}$$

# ความแปรปรวนร่วมเกี่ยว (Covariance)

พิจารณากรณีสองตัวแปร

$$\begin{aligned}\Sigma &= E \left[ \begin{bmatrix} r_1 - \mu_1 \\ r_2 - \mu_2 \end{bmatrix} \begin{bmatrix} r_1 - \mu_1 & r_2 - \mu_2 \end{bmatrix} \right] \\ &= \begin{bmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{bmatrix}\end{aligned}$$



ความแปรปรวนร่วมเกี่ยวระหว่างตัวแปรสุ่มแสดงถึงสหสัมพันธ์ (Correlation) ระหว่างตัวแปรสุ่ม ถ้าตัวแปรสุ่มเป็นอิสระต่อกันทางสถิติ แล้วความแปรปรวนร่วมเกี่ยวจะมีค่าเท่ากับศูนย์

# ความแปรปรวนร่วมเกี่ยวจะเป็นความแปรปรวนร่วมเกี่ยวทรงกลม (Spherical Covariance)

$$\Sigma = \begin{bmatrix} \sigma^2 & 0 \\ 0 & \sigma^2 \end{bmatrix}$$

ฟังก์ชันความหนาแน่นความน่าจะเป็น

เส้นโค้งค่าเสมอ (Isovalue Curve)





# ความแปรปรวนร่วมเกี่ยวจะเป็นความแปรปรวนร่วมเกี่ยวทรงรี (Ellipsoid Covariance)

$$\Sigma = \begin{bmatrix} \sigma_1^2 & 0 \\ 0 & \sigma_2^2 \end{bmatrix}$$


ฟังก์ชันความหนาแน่นความน่าจะเป็น

เส้นโค้งค่าเสมอ (Isovalue Curve)




# ความแปรปรวนร่วมเกี่ยวเป็นความแปรปรวนร่วมเกี่ยวเต็มอัตรา (Full Covariance)

ฟังก์ชันความหนาแน่นความน่าจะเป็น



เส้นโค้งค่าเสมอ (Isovalue Curve)



## ตัวจำแนกกำลังสอง (Quadratic Discriminant)

$$p(\mathbf{r}) = \frac{1}{(2\pi)^{D/2} |\boldsymbol{\Sigma}|^{1/2}} \exp \left[ -\frac{1}{2} (\mathbf{r} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{r} - \boldsymbol{\mu}) \right]$$

เมื่อใช้การแจกแจงปรกติหลายตัวแปรเป็นฟังก์ชันความหนาแน่นความน่าจะเป็นมีเงื่อนไขคลาสจะได้ฟังก์ชันจำแนก

$$\begin{aligned} g_i(\mathbf{x}) &= -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_{c_i})^T \boldsymbol{\Sigma}_{c_i}^{-1} (\mathbf{x} - \boldsymbol{\mu}_{c_i}) - \frac{|\text{Attribute}|}{2} \ln 2\pi - \frac{1}{2} \ln |\boldsymbol{\Sigma}_{c_i}| + \ln p(c_i) \\ &\quad - \ln p(\mathbf{x}) \\ &= -\frac{1}{2} \mathbf{x}^T \boldsymbol{\Sigma}_{c_i}^{-1} \mathbf{x} + \boldsymbol{\mu}_{c_i}^T \boldsymbol{\Sigma}_{c_i}^{-1} \mathbf{x} - \frac{1}{2} \boldsymbol{\mu}_{c_i}^T \boldsymbol{\Sigma}_{c_i}^{-1} \boldsymbol{\mu}_{c_i} - \frac{|\text{Attribute}|}{2} \ln 2\pi - \frac{1}{2} \ln |\boldsymbol{\Sigma}_{c_i}| + \ln p(c_i) \\ &\quad - \ln p(\mathbf{x}) \end{aligned}$$



เพื่อแสดงขั้นตอนการคำนวณหาขอบตัดสินใจของตัวจำแนกกำลังสอง  
 พิจารณาปัญหาการจำแนกซึ่งประกอบด้วยสองคลาสและตัวอย่างเข้า  $\mathbf{x}$  ประกอบด้วย  
 สองลักษณะประจำ กำหนดให้ความน่าจะเป็นก่อน  $p(c_1) = p(c_2)$ , ค่าเฉลี่ยของ  
 ตัวอย่างเข้าจากคลาส  $c_1$  คือ  $\mu_{c_1} = [2 \ 0]^T$ , ค่าเฉลี่ยของตัวอย่างเข้าจากคลาส  $c_2$  คือ  
 $\mu_{c_2} = [1 \ 0]^T$ , เมทริกซ์ความแปรปรวนร่วมเกี่ยวของตัวอย่างเข้าจากคลาส  $c_1$  คือ  
 $\Sigma_{c_1} = \begin{bmatrix} 0.5 & 0 \\ 0 & 0.25 \end{bmatrix}$  และเมทริกซ์ความแปรปรวนร่วมเกี่ยวของตัวอย่างเข้าจากคลาส  
 $c_2$  คือ  $\Sigma_{c_2} = \begin{bmatrix} 0.25 & 0 \\ 0 & 0.5 \end{bmatrix}$  จะได้ฟังก์ชันจำแนกของคลาส  $c_1$  หรือ  $g_1(\mathbf{x})$  ดังนี้

$$\begin{aligned}
 g_1(\mathbf{x}) &= -\frac{1}{2} [x_1 \ x_2] \begin{bmatrix} 2 & 0 \\ 0 & 4 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} + [2 \ 0] \begin{bmatrix} 2 & 0 \\ 0 & 4 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \\
 &\quad - \frac{1}{2} [2 \ 0] \begin{bmatrix} 2 & 0 \\ 0 & 4 \end{bmatrix} \begin{bmatrix} 2 \\ 0 \end{bmatrix} - \ln 2\pi - \frac{1}{2} \ln \begin{vmatrix} 0.5 & 0 \\ 0 & 0.25 \end{vmatrix} + \ln 0.5 - \ln p(\mathbf{x}) \quad (1-25) \\
 &= -x_1^2 - 2x_2^2 + 4x_1 - 4 - \ln 2\pi - \frac{1}{2} \ln 0.125 + \ln 0.5 - \ln p(\mathbf{x})
 \end{aligned}$$

$$\begin{aligned}
g_2(\mathbf{x}) &= -\frac{1}{2} \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} + \begin{bmatrix} 1 & 0 \end{bmatrix} \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \\
&\quad - \frac{1}{2} \begin{bmatrix} 1 & 0 \end{bmatrix} \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix} \begin{bmatrix} 1 \\ 0 \end{bmatrix} - \ln 2\pi - \frac{1}{2} \ln \begin{vmatrix} 0.25 & 0 \\ 0 & 0.5 \end{vmatrix} + \ln 0.5 - \ln p(\mathbf{x}) \\
&= -2x_1^2 - x_2^2 + 4x_1 - 2 - \ln 2\pi - \frac{1}{2} \ln 0.125 + \ln 0.5 - \ln p(\mathbf{x})
\end{aligned} \tag{1-26}$$


และจะได้ขอบตัดสนใจเป็น

$$\begin{aligned}
g(\mathbf{x}) &= g_1(\mathbf{x}) - g_2(\mathbf{x}) \\
&= x_1^2 - x_2^2 - 2 \\
&= 0
\end{aligned} \tag{1-27}$$

หรือ



$$\frac{x_1^2}{2} - \frac{x_2^2}{2} = 1 \tag{1-28}$$

# ขอบตัดสี่เหลี่ยมของตัวจำแนกกำลังสอง





$P(\omega_1) = P(\omega_2)$ ,  $\boldsymbol{\mu}_1 = [0, 0]^T$  and  $\boldsymbol{\mu}_2 = [4, 0]^T$ . The covariance matrices for the two classes are

$$\Sigma_1 = \begin{bmatrix} 0.3 & 0.0 \\ 0.0 & 0.35 \end{bmatrix}, \quad \Sigma_2 = \begin{bmatrix} 1.2 & 0.0 \\ 0.0 & 1.85 \end{bmatrix}$$




For the case of Figure 2.7b the classes are also equiprobable with  $\boldsymbol{\mu}_1 = [0, 0]^T$ ,  $\boldsymbol{\mu}_2 = [3.2, 0]^T$  and covariance matrices

$$\Sigma_1 = \begin{bmatrix} 0.1 & 0.0 \\ 0.0 & 0.75 \end{bmatrix}, \quad \Sigma_2 = \begin{bmatrix} 0.75 & 0.0 \\ 0.0 & 0.1 \end{bmatrix}$$



# Arbitrary Gaussian distributions



# ปัญหา

เมื่อปัญหาการจำแนกประกอบด้วยหลายคลาส ถ้ามีจำนวนลักษณะประจำมากแต่มีจำนวนตัวอย่างน้อย แล้วเมทริกซ์ความแปรปรวนร่วมเกี่ยวของตัวอย่างเข้าจากแต่ละคลาสจะเป็นเมทริกซ์เอกฐาน (Singular Matrix) ส่งผลให้ไม่สามารถสร้างเมทริกซ์ผกผัน (Inverse Matrix)

ปัญหานี้สามารถแก้ได้โดยการรวมตัวอย่างจากทุกคลาสและกำหนดให้เมทริกซ์ความแปรปรวนร่วมเกี่ยวของตัวอย่างเข้าจากแต่ละคลาสเป็นเมทริกซ์ความแปรปรวนร่วมเกี่ยวของตัวอย่างเข้าจากทุกคลาส ส่งผลให้จำนวนพารามิเตอร์ที่ต้องประมาณค่าลดลงและกำจัดปัญหาการสร้างเมทริกซ์ผกผันข้างต้น

## ตัวจำแนกเชิงเส้น (Linear Discriminant)

$$p(\mathbf{r}) = \frac{1}{(2\pi)^{D/2} |\mathbf{\Sigma}|^{1/2}} \exp \left[ -\frac{1}{2} (\mathbf{r} - \boldsymbol{\mu})^T \mathbf{\Sigma}^{-1} (\mathbf{r} - \boldsymbol{\mu}) \right]$$

เมื่อเมทริกซ์ความแปรปรวนร่วมเกี่ยวของตัวอย่างเข้าจากแต่ละคลาสได้รับการสมมติให้เป็นเมทริกซ์เดียวกัน ฟังก์ชันจำแนกจะสามารถเขียนได้ดังนี้

$$g_i(\mathbf{x}) = -\frac{1}{2} \mathbf{x}^T \mathbf{\Sigma}_c^{-1} \mathbf{x} + \boldsymbol{\mu}_{c_i}^T \mathbf{\Sigma}_c^{-1} \mathbf{x} - \frac{1}{2} \boldsymbol{\mu}_{c_i}^T \mathbf{\Sigma}_c^{-1} \boldsymbol{\mu}_{c_i} - \frac{|\text{Attribute}|}{2} \ln 2\pi - \frac{1}{2} \ln |\mathbf{\Sigma}_c| \\ + \ln p(c_i) - \ln p(\mathbf{x})$$

ดังนั้นขอบตัดสินใจสามารถอธิบายได้โดย

$$g_{ij}(\mathbf{x}) = g_i(\mathbf{x}) - g_j(\mathbf{x})$$

$$= (\boldsymbol{\mu}_{c_i} - \boldsymbol{\mu}_{c_j})^T \mathbf{\Sigma}_c^{-1} \mathbf{x} - \frac{1}{2} (\boldsymbol{\mu}_{c_i} - \boldsymbol{\mu}_{c_j})^T \mathbf{\Sigma}_c^{-1} (\boldsymbol{\mu}_{c_i} + \boldsymbol{\mu}_{c_j}) + \ln \left( \frac{p(c_i)}{p(c_j)} \right)$$

$$= 0$$



เพื่อแสดงขั้นตอนการคำนวณหาขอบตัดสินใจของตัวจำแนกเชิงเส้น พิจารณาปัญหาการจำแนกซึ่งประกอบด้วยสองคลาสและตัวอย่างเข้า  $\mathbf{x}$  ประกอบด้วยสองลักษณะประจำ กำหนดให้ความน่าจะเป็นก่อน  $p(c_1) = p(c_2)$ , ค่าเฉลี่ยของตัวอย่างเข้าจากคลาส  $c_1$  คือ  $\mu_{c_1} = [-1 \ -1]^T$ , ค่าเฉลี่ยของตัวอย่างเข้าจากคลาส  $c_2$  คือ  $\mu_{c_2} = [1 \ 1]^T$  และเมทริกซ์ความแปรปรวนร่วมเกี่ยวของตัวอย่างเข้าจากแต่ละคลาส คือ  $\Sigma_c = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$  จะได้ฟังก์ชันจำแนกของคลาส  $c_1$  หรือ  $g_1(\mathbf{x})$  ดังนี้

$$\begin{aligned}
 g_1(\mathbf{x}) &= -\frac{1}{2} \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} + [-1 \ -1] \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \\
 &\quad - \frac{1}{2} [-1 \ -1] \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} -1 \\ -1 \end{bmatrix} - \ln 2\pi - \frac{1}{2} \ln \begin{vmatrix} 1 & 0 \\ 0 & 1 \end{vmatrix} + \ln 0.5 - \ln p(\mathbf{x}) \\
 &= -\frac{1}{2} x_1^2 - \frac{1}{2} x_2^2 - x_1 - x_2 - 1 - \ln 2\pi + \ln 0.5 - \ln p(\mathbf{x})
 \end{aligned} \tag{1-31}$$

จะได้ฟังก์ชันจำแนกของคลาส  $c_2$  หรือ  $g_2(\mathbf{x})$  ดังนี้

$$\begin{aligned}
 g_2(\mathbf{x}) &= -\frac{1}{2} \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} + \begin{bmatrix} 1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \\
 &\quad -\frac{1}{2} \begin{bmatrix} 1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} - \ln 2\pi - \frac{1}{2} \ln \begin{vmatrix} 1 & 0 \\ 0 & 1 \end{vmatrix} + \ln 0.5 - \ln p(\mathbf{x}) \\
 &= -\frac{1}{2} x_1^2 - \frac{1}{2} x_2^2 + x_1 + x_2 - 1 - \ln 2\pi + \ln 0.5 - \ln p(\mathbf{x})
 \end{aligned} \tag{1-32}$$


และจะได้ขอบตัดสินใจเป็น


$$\begin{aligned}
 g(\mathbf{x}) &= g_1(\mathbf{x}) - g_2(\mathbf{x}) \\
 &= -2x_1 - 2x_2 \\
 &= 0
 \end{aligned} \tag{1-33}$$

หรือ




$$x_2 = -x_1 \tag{1-34}$$

# ขอบตัดสนใจของตัวจำแนกเชิงเส้น










Covariances of two distributions are equal and proportional to the identity matrix




# Priors are changed



# Asymmetric Gaussian distributions




# Different cases of the covariance matrices







# Common Covariance




# Diagonal Covariance




# Diagonal and Equal Covariance




## Population likelihoods and posteriors




Arbitrary covar.




Shared covar.



Diag. covar.



Equal var.



## การประมาณค่าพารามิเตอร์ของการแจกแจง

ถ้าการสร้างตัวจำแนกใช้การสมมติรูปแบบการแจกแจงให้กับฟังก์ชันความหนาแน่นความน่าจะเป็นมีเงื่อนไขคลาสแล้วการประมาณฟังก์ชันความหนาแน่นความน่าจะเป็นมีเงื่อนไขคลาส จะมีความซับซ้อนลดลงและเหลือเพียงการประมาณค่าพารามิเตอร์ของการแจกแจงเท่านั้น

การประมาณความควรจะเป็นสูงสุด (Maximum Likelihood Estimation)

## การประมาณความควรจะเป็นสูงสุด

กำหนดให้  $R = \{r_1, r_2, \dots, r_{|R|}\}$  เป็นเซตตัวแปรสุ่มที่มีการแจกแจงเดียวกันและเป็นอิสระต่อกัน (Independent and Identical Distribution) และให้ตัวแปรเหล่านี้ได้รับการสุ่มโดยใช้ฟังก์ชันควรจะเป็นตัวแปรเดียว  $l(r_i | \theta)$  ซึ่งสามารถนิยามโดย

$$l(r_i | \theta) = p(r_i | \theta) \quad (1-43)$$

โดยที่  $p(r_i | \theta)$  คือความน่าจะเป็นที่ตัวแปร  $r_i$  ได้รับการสุ่มโดยอิงจากการแจกแจงซึ่งมีพารามิเตอร์เป็น  $\theta$  เนื่องจากแต่ละตัวแปรสุ่มเป็นอิสระต่อกัน ดังนั้นฟังก์ชันควรจะเป็นมีเงื่อนไขตัวแปรสุ่ม  $l(\theta | R)$  คือผลคูณของความน่าจะเป็นของแต่ละตัวแปรสุ่ม หรือ



$$l(\theta | R) = \prod_{i=1}^{|R|} p(r_i | \theta) \quad (1-44)$$

## การประมาณความควรจะเป็นสูงสุด

เมื่อใช้ฟังก์ชันลอการิทึม (Logarithm Function) กับสมการที่ (1-44) ฟังก์ชันลอการจะเป็น (Log-Likelihood Function) มีเงื่อนไขตัวแปรสุ่ม  $L(\theta | R)$  จะสามารถอธิบายได้โดย

$$L(\theta | R) = \log(l(\theta | R)) = \sum_{i=1}^{|R|} \log p(r_i | \theta) \quad (1-45)$$

# ฟังก์ชันควรจะเป็นมีเงื่อนไขตัวแปรสุ่ม





## การประมาณค่าพารามิเตอร์ของการแจกแจงปกติโดยการประมาณความควรจะเป็นสูงสุด

ฟังก์ชันลอกลความควรจะเป็นมีเงื่อนไขตัวอย่างเข้าจะสามารถอธิบายได้โดย

$$\begin{aligned} L(\mu, \sigma^2 | S) &= \ln \prod_{i=1}^{|S|} p(x_i | \mu, \sigma^2) \\ &= \ln \prod_{i=1}^{|S|} \frac{1}{\sqrt{2\pi\sigma}} \exp \left[ -\frac{1}{2} \left( \frac{x_i - \mu}{\sigma} \right)^2 \right] \\ &= -\frac{|S|}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^{|S|} (x_i - \mu)^2 \end{aligned}$$

## ค่าเฉลี่ยของตัวอย่างเข้า

$$-\frac{|S|}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^{|S|} (x_i - \mu)^2$$

ค่าเฉลี่ยที่ทำให้ฟังก์ชันลอการิทึมจะเป็นมีเงื่อนไขมีค่าสูงสุดคือค่าเฉลี่ยที่ทำให้อนุพันธ์ (Derivative) ของฟังก์ชันลอการิทึมจะเป็นมีเงื่อนไขมีค่าเป็นศูนย์ นั่นคือ

$$\frac{\partial L(\mu, \sigma^2 | S)}{\partial \mu} = \frac{1}{\sigma^2} \sum_{i=1}^{|S|} (x_i - \mu) = 0$$

ส่งผลให้

$$\mu = \frac{1}{|S|} \sum_{i=1}^{|S|} x_i$$

## ความแปรปรวนของตัวอย่างเข้า

$$-\frac{|S|}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^{|S|} (x_i - \mu)^2$$

ความแปรปรวนที่ทำให้ฟังก์ชันลอการิทึมจะเป็นมีเงื่อนไขมีค่าสูงสุดคือ  
ความแปรปรวนที่ทำให้อนุพันธ์ของฟังก์ชันลอการิทึมจะเป็นมีเงื่อนไขมีค่า  
เป็นศูนย์ นั่นคือ

$$\frac{\partial L(\mu, \sigma^2 | S)}{\partial \sigma^2} = -\frac{|S|}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^{|S|} (x_i - \mu)^2 = 0$$

ส่งผลให้

$$\sigma^2 = \frac{1}{|S|} \sum_{i=1}^{|S|} (x_i - \mu)^2$$

## การประมาณค่าพารามิเตอร์ของการแจกแจงปรกติหลายตัวแปร

ฟังก์ชันลอการิทึมจะเป็นมีเงื่อนไขตัวอย่างเข้าจะสามารถอธิบายได้โดย

$$\begin{aligned} L(\boldsymbol{\mu}, \boldsymbol{\Sigma} \mid S) &= \ln \prod_{i=1}^{|S|} p(\mathbf{x}_i \mid \boldsymbol{\mu}, \boldsymbol{\Sigma}) \\ &= \ln \prod_{i=1}^{|S|} \frac{1}{(2\pi)^{|Attribute|/2} |\boldsymbol{\Sigma}|^{1/2}} \exp \left[ -\frac{1}{2} (\mathbf{x}_i - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x}_i - \boldsymbol{\mu}) \right] \\ &= -\frac{|S|}{2} \ln((2\pi)^{|Attribute|} |\boldsymbol{\Sigma}|) - \frac{1}{2} \sum_{i=1}^{|S|} (\mathbf{x}_i - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x}_i - \boldsymbol{\mu}) \end{aligned}$$

# เวกเตอร์ค่าเฉลี่ยและเมทริกซ์ความแปรปรวนร่วมเกี่ยว

เช่นเดียวกับกรณีการแจกแจงปกติตัวแปรเดียว เวกเตอร์ค่าเฉลี่ยของตัวอย่างเข้า  $\mu$  ที่ทำให้ฟังก์ชันลอกลการจะเป็นมีเงื่อนไขตัวอย่างเข้า  $L(\mu, \Sigma | S)$  มีค่าสูงสุดคือ

$$\mu = \frac{1}{|S|} \sum_{i=1}^{|S|} \mathbf{x}_i \quad (1-52)$$

และเมทริกซ์ความแปรปรวนร่วมเกี่ยวของตัวอย่างเข้า  $\Sigma$  ที่ทำให้ฟังก์ชันลอกลการจะเป็นมีเงื่อนไขตัวอย่างเข้า  $L(\mu, \Sigma | S)$  มีค่าสูงสุดคือ

$$\Sigma = \frac{1}{|S|} \sum_{i=1}^{|S|} (\mathbf{x}_i - \mu)(\mathbf{x}_i - \mu)^T \quad (1-53)$$

# เบย์อย่างง่าย

- การแสดงแบบจำลอง
  - ใช้ลักษณะประจำทุกตัว
  - ลักษณะประจำแต่ละตัวอิสระต่อกัน
- เกณฑ์ประเมินแบบจำลอง
  - ความน่าจะเป็นภายหลัง (Posterior probability)
- วิธีการค้นหา
  - ไม่ต้องค้นหา

# ข้อมูลสภาพภูมิอากาศ

| Outlook  | Temp | Humidity | Windy | Play |
|----------|------|----------|-------|------|
| Sunny    | Hot  | High     | FALSE | No   |
| Sunny    | Hot  | High     | TRUE  | No   |
| Overcast | Hot  | High     | FALSE | Yes  |
| Rainy    | Mild | High     | FALSE | Yes  |
| Rainy    | Cool | Normal   | FALSE | Yes  |
| Rainy    | Cool | Normal   | TRUE  | No   |
| Overcast | Cool | Normal   | TRUE  | Yes  |
| Sunny    | Mild | High     | FALSE | No   |
| Sunny    | Cool | Normal   | FALSE | Yes  |
| Rainy    | Mild | Normal   | FALSE | Yes  |
| Sunny    | Mild | Normal   | TRUE  | Yes  |
| Overcast | Mild | High     | TRUE  | Yes  |
| Overcast | Hot  | Normal   | FALSE | Yes  |
| Rainy    | Mild | High     | TRUE  | No   |

# ความน่าจะเป็นสำหรับข้อมูลสภาพภูมิอากาศ

| Outlook  |   |   | Temperature |   |   | Humidity |   |   | Windy  |   |   | Play |    |
|----------|---|---|-------------|---|---|----------|---|---|--------|---|---|------|----|
| Yes No   |   |   | Yes No      |   |   | Yes No   |   |   | Yes No |   |   | Yes  | No |
| Sunny    | 2 | 3 | Hot         | 2 | 2 | High     | 3 | 4 | False  | 6 | 2 | 9    | 5  |
| Overcast | 4 | 0 | Mild        | 4 | 2 | Normal   | 6 | 1 | True   | 3 | 3 |      |    |
| Rainy    | 3 | 2 | Cool        | 3 | 1 |          |   |   |        |   |   |      |    |

| Outlook  |     |     | Temperature |     |     | Humidity |     |     | Windy  |     |     | Play |      |
|----------|-----|-----|-------------|-----|-----|----------|-----|-----|--------|-----|-----|------|------|
| Yes No   |     |     | Yes No      |     |     | Yes No   |     |     | Yes No |     |     | Yes  | No   |
| Sunny    | 2/9 | 3/5 | Hot         | 2/9 | 2/5 | High     | 3/9 | 4/5 | False  | 6/9 | 2/5 | 9/14 | 5/14 |
| Overcast | 4/9 | 0/5 | Mild        | 4/9 | 2/5 | Normal   | 6/9 | 1/5 | True   | 3/9 | 3/5 |      |      |
| Rainy    | 3/9 | 2/5 | Cool        | 3/9 | 1/5 |          |     |     |        |     |     |      |      |



## การจำแนกวันใหม่

| Outlook | Temp. | Humidity | Windy | Play |
|---------|-------|----------|-------|------|
| Sunny   | Cool  | High     | True  | ?    |

ผลคูณของความน่าจะเป็นของทั้งสองคลาส

- “yes” =  $2/9 \times 3/9 \times 3/9 \times 3/9 \times 9/14 = 0.0053$
- “no” =  $3/5 \times 1/5 \times 4/5 \times 3/5 \times 5/14 = 0.0206$

แปลงให้อยู่ในรูปของความน่าจะเป็น

- $P(\text{“yes”}) = 0.0053 / (0.0053 + 0.0206) = 0.205$
- $P(\text{“no”}) = 0.0206 / (0.0053 + 0.0206) = 0.795$

# กฎของเบย์

- ความน่าจะเป็นของเหตุการณ์ (Event)  $H$  เมื่อให้หลักฐาน (Evidence)  $E$

$$\Pr[H|E] = \frac{\Pr[E|H]\Pr[H]}{\Pr[E]}$$

- ความน่าจะเป็นก่อนหน้า (Prior probability) ของ  $H$  ( $\Pr[H]$ )  
คือ ความน่าจะเป็นของเหตุการณ์ก่อนที่พบหลักฐาน
- ความน่าจะเป็นภายหลัง (Posteriori probability) of  $H$  ( $\Pr[H|E]$ )  
คือ ความน่าจะเป็นของเหตุการณ์หลังจากพบหลักฐาน

# การจำแนกประเภทด้วยเบย์อย่างง่าย

- ความน่าจะเป็นของคลาสเมื่อมีตัวอย่าง
  - หลักฐาน  $E$  คือ ตัวอย่าง
  - เหตุการณ์  $H$  คือ คลาสของตัวอย่าง
- สมมติฐานของเบย์อย่างง่าย คือ หลักฐานแบ่งออกเป็นหลายส่วนที่อิสระต่อกัน (ลักษณะประจำ)

$$\Pr[H|E] = \frac{\Pr[E_1|H] \Pr[E_2|H] \dots \Pr[E_n|H] \Pr[H]}{\Pr[E]}$$

# ปัญหาความถี่ศูนย์

- จะเกิดอะไรขึ้นถ้าค่าของลักษณะประจำไม่ปรากฏในคลาส (เช่น “Humidity = high” สำหรับคลาส “yes”)
  - ความน่าจะเป็นจะมีค่าเป็นศูนย์  $\Pr[\text{Humidity} = \text{High} | \text{yes}] = 0$
  - ความน่าจะเป็นภายหลังจะมีค่าเป็นศูนย์  $\Pr[\text{yes} | E] = 0$
- วิธีแก้ไข
  - บวก 1 ในการนับความถี่ของค่าลักษณะประจำ (Laplace estimator)
- ผลลัพธ์
  - ความน่าจะเป็นจะไม่เป็นศูนย์

## การปรับปรุงการประมาณค่าความน่าจะเป็น

- บางกรณีการบวกค่าคงที่ที่ไม่เท่ากับ 1 อาจจะเหมาะสมกว่า
- ตัวอย่าง ลักษณะประจำ outlook สำหรับคลาส yes

Sunny

Overcast

Rainy

$$\frac{2+\mu/3}{9+\mu}$$

$$\frac{4+\mu/3}{9+\mu}$$

$$\frac{3+\mu/3}{9+\mu}$$

- ค่าถ่วงน้ำหนักไม่จำเป็นต้องเท่ากันเสมอไปแต่ต้องรวมกันเท่ากับ 1

$$\frac{2+\mu p_1}{9+\mu}$$

$$\frac{4+\mu p_2}{9+\mu}$$

$$\frac{3+\mu p_1}{9+\mu}$$

## ค่าสูญหาย (Missing values)

| Outlook | Temp. | Humidity | Windy | Play |
|---------|-------|----------|-------|------|
| ?       | Cool  | High     | True  | ?    |

การเรียนรู้: ตัวอย่างนี้จะไม่ถูกรวมเข้าไปในการนับความถี่

การจำแนก: ลักษณะประจำนี้จะไม่นำไปคำนวณ

- Likelihood of “yes” =  $3/9 \times 3/9 \times 3/9 \times 9/14 = 0.0238$
- Likelihood of “no” =  $1/5 \times 4/5 \times 3/5 \times 5/14 = 0.0343$
- $P(\text{“yes”}) = 0.0238 / (0.0238 + 0.0343) = 41\%$
- $P(\text{“no”}) = 0.0343 / (0.0238 + 0.0343) = 59\%$

# ลักษณะประจำเชิงตัวเลข

- สมมติฐาน คือ ลักษณะประจำมีการกระจายตัวแบบปกติ
- ฟังก์ชันความหนาแน่นความน่าจะเป็น (Probability density function) สำหรับการแจกแจงแบบปกตินิยามโดยพารามิเตอร์สองตัว:

- ค่าเฉลี่ย

$$\mu = \frac{1}{n} \sum_{i=1}^n x_i$$

- ส่วนเบี่ยงเบนมาตรฐาน

$$\sigma^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \mu)^2$$

- ฟังก์ชันความหนาแน่น

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

# ความน่าจะเป็นสำหรับข้อมูลสภาพภูมิอากาศ

| Outlook  |    |   | Temperature |         | Humidity |         | Windy |    |   | Play |    |
|----------|----|---|-------------|---------|----------|---------|-------|----|---|------|----|
| Yes      | No |   | Yes         | No      | Yes      | No      | Yes   | No |   | Yes  | No |
| Sunny    | 2  | 3 | 64, 68,     | 65, 71, | 65, 70,  | 70, 85, | False | 6  | 2 | 9    | 5  |
| Overcast | 4  | 0 | 69, 70,     | 72, 80, | 70, 75,  | 90, 91, | True  | 3  | 3 |      |    |
| Rainy    | 3  | 2 | 72, ...     | 85, ... | 80, ...  | 95, ... |       |    |   |      |    |

| Outlook  |     |     | Temperature    |                | Humidity        |                | Windy |     |     | Play |      |
|----------|-----|-----|----------------|----------------|-----------------|----------------|-------|-----|-----|------|------|
| Yes      | No  |     | Yes            | No             | Yes             | No             | Yes   | No  |     | Yes  | No   |
| Sunny    | 2/9 | 3/5 | $\mu = 73$     | $\mu = 75$     | $\mu = 79$      | $\mu = 86$     | False | 6/9 | 2/5 | 9/14 | 5/14 |
| Overcast | 4/9 | 0/5 | $\sigma = 6.2$ | $\sigma = 7.9$ | $\sigma = 10.2$ | $\sigma = 9.7$ | True  | 3/9 | 3/5 |      |      |
| Rainy    | 3/9 | 2/5 |                |                |                 |                |       |     |     |      |      |



## การจำแนกวันใหม่

| Outlook | Temp. | Humidity | Windy | Play |
|---------|-------|----------|-------|------|
| Sunny   | 66    | 90       | True  | ?    |

Likelihood of “yes” =  $2/9 \times 0.0340 \times 0.0221 \times 3/9 \times 9/14 = 0.000036$

Likelihood of “no” =  $3/5 \times 0.0291 \times 0.0380 \times 3/5 \times 5/14 = 0.000136$

$P(\text{“yes”}) = 0.000036 / (0.000036 + 0.000136) = 20.9\%$

$P(\text{“no”}) = 0.000136 / (0.000036 + 0.000136) = 79.1\%$

## การแจกแจงแบร์นูลลี

$$p(r) = p_{Success}^r (1 - p_{Success})^{1-r}$$

ค่าคาดหวังและความแปรปรวนของตัวแปรสุ่ม  $r$  สามารถอธิบายได้โดย

$$E[r] = \sum_r r p(r) = 1 \times p_{Success} + 0 \times (1 - p_{Success}) = p_{Success}$$

และ

$$\text{Var}(r) = \sum_r (r - E[r])^2 p(r) = p_{Success} (1 - p_{Success})$$

# ความหนาแน่นความน่าจะเป็นมีเงื่อนไขคลาส

ถ้าตัวอย่างเข้าประกอบด้วยหลายลักษณะประจำค่าวิฤต แล้วจำนวนค่าความน่าจะเป็นสำเร็จ จะมีการเพิ่มแบบเลขชี้กำลัง (Exponential Growth) ตามจำนวนลักษณะประจำ

ดังนั้นจึงมักสมมติให้แต่ละลักษณะประจำค่าวิฤตเป็นอิสระต่อกัน

เมื่อใช้การแจกแจงแบร์นูลลีหลายตัวแปรซึ่งเป็นอิสระต่อกันเป็นฟังก์ชันความหนาแน่นความน่าจะเป็นมีเงื่อนไขคลาส

$$p(\mathbf{x} | c_i) = \prod_{j=1}^{|Attribute|} p_{c_{ij}}^{x_j} (1 - p_{c_{ij}})^{(1-x_j)}$$

# ตัวจำแนกเบส์สามัญ (Naïve Bayes Classifier)

ฟังก์ชันจำแนก

$$g_i(\mathbf{x}) = \sum_{j=1}^{|Attribute|} (x_j \ln p_{c_{ij}} + (1-x_j) \ln(1-p_{c_{ij}})) + \ln p(c_i) - \ln p(\mathbf{x})$$

ขอบตัดสินใจ

$$g(\mathbf{x}) = g_1(\mathbf{x}) - g_2(\mathbf{x})$$

$$= \sum_{j=1}^{|Attribute|} \left( x_j \ln \left( \frac{p_{c_{1j}}}{p_{c_{2j}}} \right) + (1-x_j) \ln \left( \frac{1-p_{c_{1j}}}{1-p_{c_{2j}}} \right) \right) + \ln \left( \frac{p(c_1)}{p(c_2)} \right)$$

$$= \sum_{j=1}^{|Attribute|} x_j \ln \left( \frac{p_{c_{1j}} (1-p_{c_{2j}})}{p_{c_{2j}} (1-p_{c_{1j}})} \right) + \sum_{j=1}^{|Attribute|} \ln \left( \frac{1-p_{c_{1j}}}{1-p_{c_{2j}}} \right) + \ln \left( \frac{p(c_1)}{p(c_2)} \right)$$

$$= 0$$


เพื่อแสดงขั้นตอนการคำนวณหาขอบตัดสินใจของตัวจำแนกเบย์ส์สามัญ  
พิจารณาปัญหาการจำแนกซึ่งประกอบด้วยสองคลาสและตัวอย่างเข้า  $\mathbf{x}$  ประกอบด้วย  
สองลักษณะประจำ กำหนดให้ความน่าจะเป็นก่อน  $p(c_1) = p(c_2)$  และ  
ความน่าจะเป็นสำเร็จ  $p_{c_{11}} = p_{c_{12}} = 0.8$  และ  $p_{c_{21}} = p_{c_{22}} = 0.5$  จะได้ขอบตัดสินใจดังนี้

$$\begin{aligned} g(\mathbf{x}) &= x_1 \ln \left( \frac{0.8(1-0.5)}{0.5(1-0.8)} \right) + x_2 \ln \left( \frac{0.8(1-0.5)}{0.5(1-0.8)} \right) + 2 \ln \left( \frac{1-0.8}{1-0.5} \right) + \ln \left( \frac{0.5}{0.5} \right) \\ &= 1.3863x_1 + 1.3863x_2 - 1.8326 \\ &= 0 \end{aligned} \tag{1-41}$$

หรือ

$$x_2 = -x_1 + 1.3219 \tag{1-42}$$

# ขอบตัดสนใจของตัวจำแนกเบสส์สามัญ



## การประมาณค่าพารามิเตอร์ของการแจกแจงแบร์นูลลีโดยการประมาณความควรจะเป็นสูงสุด

ฟังก์ชันลอกลการจะเป็นมีเงื่อนไขตัวอย่างเข้าจะสามารถอธิบายได้โดย

$$\begin{aligned} L(p_{\text{Success}} | S) &= \ln \prod_{i=1}^{|S|} p_{\text{Success}}^{x_i} (1 - p_{\text{Success}})^{(1-x_i)} \\ &= \sum_{i=1}^{|S|} (x_i \ln p_{\text{Success}} + (1 - x_i) \ln(1 - p_{\text{Success}})) \end{aligned}$$

ความน่าจะเป็นสำเร็จที่ทำให้ฟังก์ชันลอกลการจะเป็นมีเงื่อนไข มีค่าสูงสุด คือความน่าจะเป็นสำเร็จที่ทำให้อนุพันธ์ของฟังก์ชันลอกลการจะเป็นมีเงื่อนไขมีค่าเป็นศูนย์ นั่นคือ

$$\frac{dL(p_{\text{success}} | S)}{dp_{\text{Success}}} = \frac{1}{p_{\text{Success}}} \sum_{i=1}^{|S|} x_i - \frac{1}{1 - p_{\text{Success}}} \left( |S| - \sum_{i=1}^{|S|} x_i \right) = 0$$

ส่งผลให้

$$p_{\text{Success}} = \frac{1}{|S|} \sum_{i=1}^{|S|} x_i$$

# การประมาณค่าพารามิเตอร์ของการแจกแจงแบร์นูลลีหลายตัวแปร

ฟังก์ชันลอกลอการจะเป็นมีเงื่อนไขตัวอย่างเข้า จะสามารถอธิบายได้โดย

$$L(p_{Success_1}, \dots, p_{Success_{|Attribute|}} | S) = \ln \prod_{i=1}^{|S|} \prod_{j=1}^{|Attribute|} p_{Success_j}^{x_{ij}} (1 - p_{Success_j})^{(1-x_{ij})}$$

เช่นเดียวกับกรณีการแจกแจงแบร์นูลลีตัวแปรเดียวข้างต้น ความน่าจะเป็น  
สำเร็จที่ทำให้ฟังก์ชันลอกลอการจะเป็นมีเงื่อนไขตัวอย่างเข้า มีค่าสูงสุดคือ

$$p_{Success_j} = \frac{1}{|S|} \sum_{i=1}^{|S|} x_{ij}$$